




Sampling based inference

Overview

- Introduction to sampling
- Rejection sampling
- Importance sampling
- MCMC (Markov Chain Monte Carlo)
- M-H sampling (Gibbs sampling)

What is sampling

- Sampling: obtaining a small sample s to represent the whole data set N : 모집단과 유사한 일부 데이터 추출
 - Allow a mining algorithm to run in complexity that is potentially sub-linear to the size of the data
 - Reduction of continuous signal to discrete signal
- Sampling in statistics
 - Extracting samples from a distribution $p(x)$
- Random sampling
 - Easy?
 - Samples are extracted with the same probability
 - 무작위 추출 때, 모집단에서 각 개체가 추출될 확률은 모두 같다고 봄
- Is sampling difficult?
 - N 개로 구간을 쪼갰 다음 각 구간의 중심값으로만 샘플링?
 - 상태 개수가 N 개로 고정되어 버림
 - 양 끝쪽의 샘플을 정확히 얻을 수 없음




Why do we need sampling?

- Optimization problem solving
- Is it easy to know mean value?

$$\int f(x)p(x)dx \approx \sum_{i=1}^N \frac{f(X_i)}{N}$$

- Bayesian

$$p(\theta|D) = \frac{p(D|\theta)p(\theta)}{p(D)}$$


Calculation is not easy

- When sampling is required
 1. To solve an optimization problem. 높은 차원의 최적화 문제를 풀 때
 2. To solve integral. 높은 차원의 적분을 할 때
 3. To calculate a mean of distribution. 특정 확률밀도함수의 평균값 계산
 4. To get a probability value at a point. 특정 확률값 계산

Application: RL Optimization using sampling

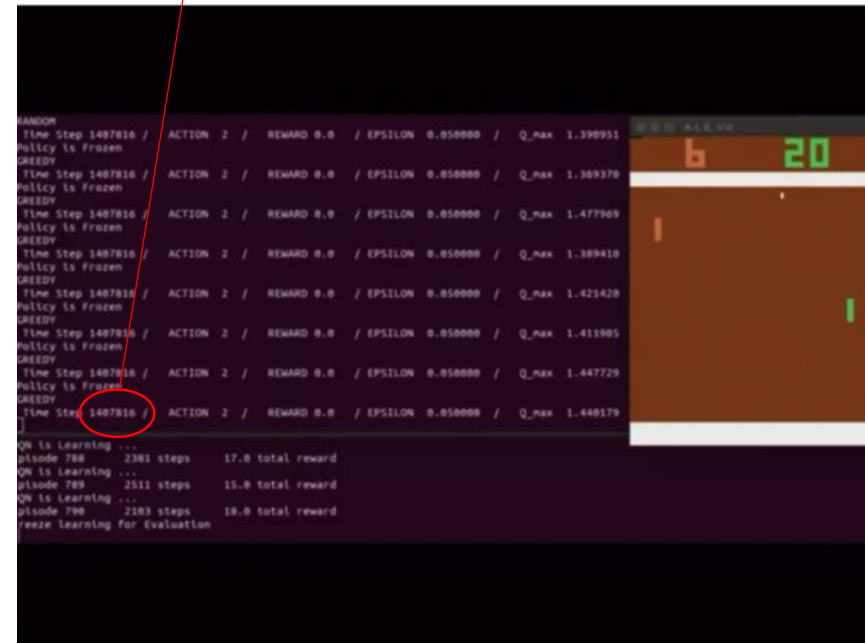
- Many trials to reach the optimum

Algorithm 1 Deep Q-learning with Experience Replay

```

Initialize replay memory  $\mathcal{D}$  to capacity  $N$ 
Initialize action-value function  $Q$  with random weights
for episode = 1,  $M$  do
  Initialise sequence  $s_1 = \{x_1\}$  and preprocessed sequenced  $\phi_1 = \phi(s_1)$ 
  for  $t = 1, T$  do
    With probability  $\epsilon$  select a random action  $a_t$ 
    otherwise select  $a_t = \max_a Q^*(\phi(s_t), a; \theta)$ 
    Execute action  $a_t$  in emulator and observe reward  $r_t$  and image  $x_{t+1}$ 
    Set  $s_{t+1} = s_t, a_t, x_{t+1}$  and preprocess  $\phi_{t+1} = \phi(s_{t+1})$ 
    Store transition  $(\phi_t, a_t, r_t, \phi_{t+1})$  in  $\mathcal{D}$ 
    Sample random minibatch of transitions  $(\phi_j, a_j, r_j, \phi_{j+1})$  from  $\mathcal{D}$ 
    Set  $y_j = \begin{cases} r_j & \text{for terminal } \phi_{j+1} \\ r_j + \gamma \max_{a'} Q(\phi_{j+1}, a'; \theta) & \text{for non-terminal } \phi_{j+1} \end{cases}$ 
    Perform a gradient descent step on  $(y_j - Q(\phi_j, a_j; \theta))^2$  according to equation 3
  end for
end for
  
```


Over 1.4 million trials



Random Sampling


- Key principle: Choose a **representative** subset of the data
- Note: Sampling may not reduce database I/Os (page at a time)
- **Simple random sampling**
 - There is an equal probability of selecting any particular item
- **Sampling without replacement**
 - Once an object is selected, it is removed from the population
- **Sampling with replacement**
 - A selected object is not removed from the population
- **Stratified sampling:**
 - Partition the data set, and draw samples from each partition (proportionally, i.e., approximately the same percentage of the data)
 - Used in conjunction with skewed data
- **Systematic sampling**
 - 모집단에 있는 관찰값들에게 번호를 임의로 배정한 후 추출 간격을 두어 추출
- **Cluster sampling**
 - 전체 자료를 집락으로 나누어, 몇 개의 샘플 집단을 랜덤 추출해 추출된 집락 내의 데이터를 전수 조사 하는 샘플링

Sampling: With or without Replacement




Sampling: Cluster or Stratified Sampling

Raw Data




Cluster/Stratified Sample



Forward sampling

- Generate samples based on the probability of the BN

- Many samples

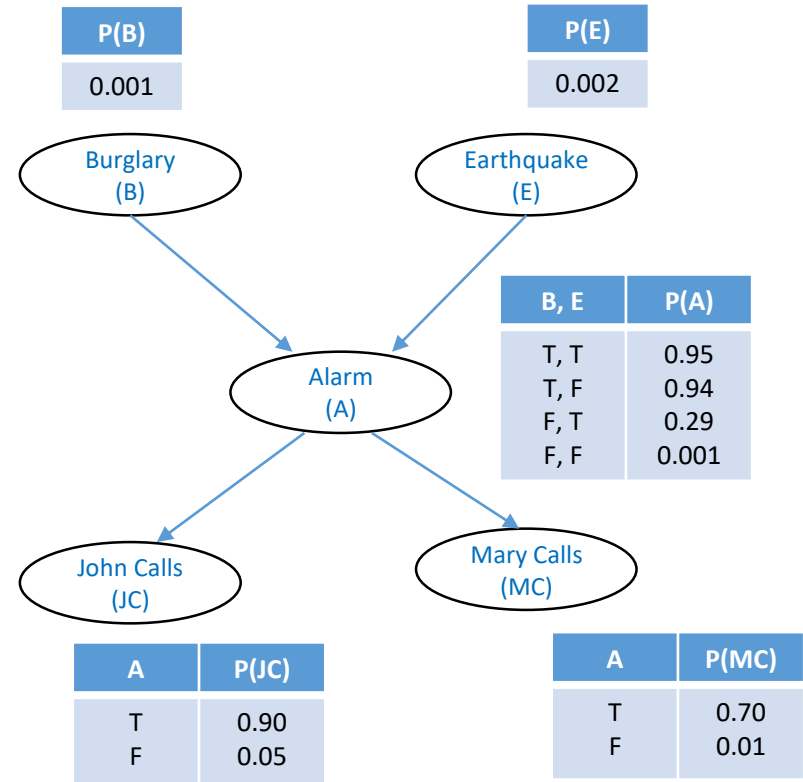


- Count the numbers

- $P(E=T|MC=T, A=T)$?
- 계속 해본 뒤, 위의 경우를 만족하는 경우를 카운트

- What are problems of FS?


- Error from random cases
 - Random case라 오차 발생 가능
- It takes long time
 - 시행 횟수가 많을수록 시간이 많이 걸림



Rejection sampling

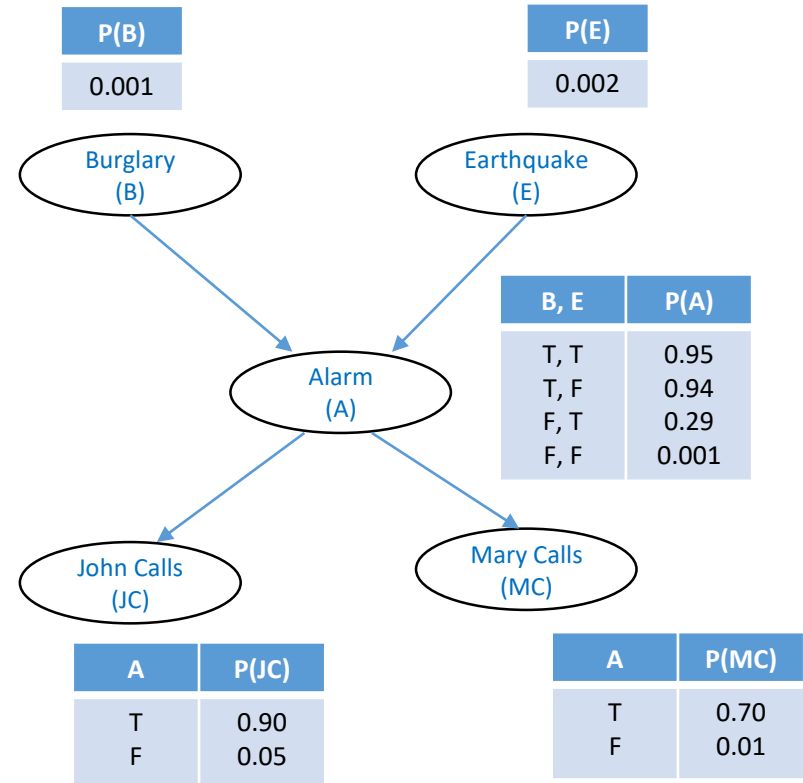
- If a sample doesn't satisfy the condition discard it.

- If $P(E|MC=T, A=T)$
- Count only the number of samples $MC='T'$ and $A='T'$



- Reject cases which do not satisfy the condition
 - 카운트하는 중간에 해당 조건을 만족못하면 카운트 하지 않음

- $P(E|MC, A) = P(E, MC, A) / P(MC, A)$
 - $P(E, MC, A) / (\# \text{ of accepted samples})$



Rejection sampling


- In the continuous variable
 - Use a known distribution $q(x)$ (ex. *Normal*)
 - $u \sim U(0,1)$

$$\text{if } \frac{p(x)}{Mq(x)} < u, \text{ reject } x$$

- How to find M ?

$$p(\text{accept}) = \int \left\{ \frac{p(x)}{Mq(x)} \right\} q(x) dx = \frac{1}{M} \int p(x) dx$$

- Acceptance rate is inversely proportional to M
- Find a smallest M which satisfy $p(x) \leq Mq(x)$



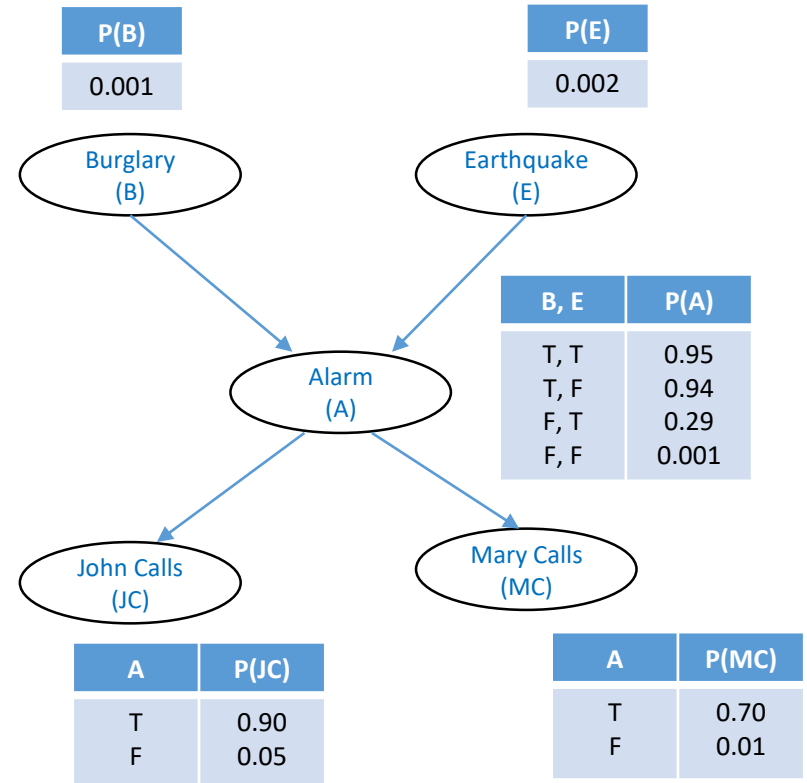
```
def p(x):  
    return st.norm.pdf(x, loc=30, scale=10) + st.norm.pdf(x, loc=80, scale=20)  
  
def q(x):  
    return st.norm.pdf(x, loc=50, scale=30)  
  
[4] x = np.arange(-50, 151)  
    k = max(p(x) / q(x))
```

```
def rejection_sampling(iter=1000):  
    samples = []  
  
    for i in range(iter):  
        z = np.random.normal(50, 30)  
        u = np.random.uniform(0, 1)  
        if u <= p(z)/(k*q(z)):  
            samples.append(z)  
    return np.array(samples)
```

Importance sampling

■ $P(E = T | MC = T, A = F) = ?$

- $SumSW = TotSW = 0$
- Loop
 - $sw(\text{Sampling weight}) = 1$
 - ✓ $B=F$
 - ✓ $E=F$
 - ✓ $A=F|B=F, E=F$
 - $sw = 1 * 0.999$
 - ✓ $JC|A=T$
 - ✓ $MC=T|A=F$
 - $sw = sw * 0.01$
 - If $E==T \Rightarrow SumSW = SumSW + sw$
 - $TotSW = TotSW + sw$
- Importance: $SumSW / TotSW$



Importance sampling

- The goal of sampling

- Calculating the expectation of PDF
- Calculating a certain probability

즉, 위 2가지만 잘 할 수 있으면 sampling을 여러 번 하지 않아도 됨(rejection sampling 보완)
→ **Importance sampling** 도입

$$E[f(z)] = \int_z f(z)p(z)dz = \int_z \frac{f(z)p(z)}{q(z)}q(z)dz \left\{ \begin{array}{l} \cong \frac{1}{L} \sum_{l=1}^L \frac{p(z^l)}{q(z^l)} f(z^l) \\ E_{z \sim q} \left[\frac{p(z)}{q(z)} f(z) \right] \end{array} \right.$$

- z : 확률변수
- p : 확률변수 z 의 확률분포 → 정확히 알 수 없다.
- f : 임의의 함수
- q : p 에서 샘플 생성 어려울 때 → 비교적 샘플의 생성이 쉬운 q 에서 샘플 생성
→ f 기댓값 계산

Code

```
[42] value_list = []
      for i in range(n):
          # sample from different distribution
          x_i = np.random.normal(mu_appro, sigma_appro)
          value = f_x(x_i)*(p_x.pdf(x_i) / q_x.pdf(x_i))

          value_list.append(value)
```

Algorithm 1: Sampling-importance-resampling

Input : the number of samples N ,
nominal distribution p ,
proposal distribution q

Output: samples $X = \{x_1, x_2, \dots, x_N\}$

```
1  $X = \{\}$ 
2  $Z = \{\}$ 
3 for  $n = 1 : N$  do
4    $Z \leftarrow Z \cup \{z_n\}$     $z_n \sim q$ 
5 end
6 for  $n = 1 : N$  do
7    $w_n = \frac{p(z_n)/q(z_n)}{\sum_{i=1}^N p(z_i)/q(z_i)}$ 
8 end
9 generate  $N$  samples using  $w$ .
```

MCMC = MC (Monte Carlo) + MC (Markov Chain)

■ Monte Carlo

- Simulation method by sampling
 - 통계적 수치를 얻기 위한 Simulation
 - 무한히 많은 시도가 불가능하기 때문에
 - 유한한 시도만으로 추정



Stanisław Marcin Ulam



■ Markov Chain

- State change
 - 시간에 따른 계의 상태 변화


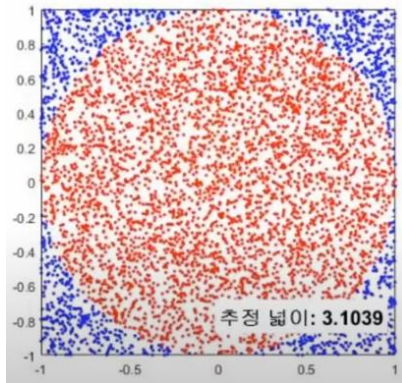
$$P(Z_i|Z_{i-1}, \dots, Z_1) = P(Z_i|Z_{i-1})$$



Andrei Andreyevich Markov

MCMC 원리

■ MC



■ MC

- 가장 마지막에 뽑힌 샘플이 다음 번 샘플을 추천

MCMC

■ Markov Chain

- a stochastic model describing a sequence of possible events
 - 마코프 가정(Markov assumption)을 따르는 이산 시간 확률 과정
- $P(Z_i|Z_{i-1}, \dots, Z_1) = P(Z_i|Z_{i-1})$
 - 특정 시점의 상태 확률은 단지 그 이전 상태에만 의존한다 =
- Stationary Distribution
 - 특정 조건을 만족한 상태에서 Markov Chain을 반복하다 보면 현재 상태의 확률이 직전 상태의 확률과 같아지게(수렴) 된다. 평형 상태에 도달한 확률 분포를 정적 분포(Stationary Distribution)
 - 특정조건 : 기약, 에르고딕(양의 재귀적&비주기적)

■ Monte Carlo

- to model the probability of different outcomes in a process that cannot easily be predicted due to the intervention of random variables.
 - 랜덤 표본을 뽑아 함수의 값을 확률적으로 계산하는 알고리즘

■ MCMC

- 조건
 - Easy to generate samples: $P(Z_{n+1}|Z_n)$ 으로부터 표본을 생성하기 쉬워야 한다.
 - Target distribution is stationary distribution: 관심 있는 목표분포가 마르코프 연쇄의 정상분포가 되어야 한다.
- Markov Chain에 기반한 확률 분포로부터 표본을 추출하는 Monte Carlo방법
 - 초기값 Z_0 를 지정한다
 - 마르코프 연쇄가 정상분포에 도달할 때까지 N 개의 관측값 $\{Z_n, n = 1, \dots, N\}$ 을 생성한다
 - 수렴진단 방법을 이용하여 알고리즘의 수렴 여부를 확인한다. 만약 수렴하지 않으면, 더 많은 관측값을 생성
 - 초기 B 개의 관측값을 제거한 후, $\{Z_{B+1}, \dots, Z_N\}$ 을 분석을 위한 표본으로 간주한다.
 - 생성한 표본을 이용하여, 요약통계량(평균, 중앙값, 표준편차, 분위수, 상관계수 등) 및 표본을 추정한다
- Markov Chain Sample은 iid(Independent and Identically distributed)가 아님


MCMC

■ Why do we use MCMC?

1. Fast convergence: 빠른 수렴 속도
2. 더 많은 확률분포 샘플링 가능

■ Difference from the other sampling methods

- Use historical records: 기존 샘플링의 문제점은 과거의 레코드는 사용하지 않음
- Rejection sampling은 조건이 맞지 않으면 버림
- Importance sampling은 개별 sample들이 다 독립이었음



MCMC가 특정 확률 분포를 샘플링 하는 과정

MCMC procedure

- Step1: randomly select the first sample
- Step2: recommend the next sample from it (use the proposed distribution)
- Step3: Accept or Reject
- Step4: repeat step 2 and 3

Proposal Distribution

- If proposal distribution is asymmetric?
 - M-H (Metropolis Hastings)

M-H algorithm (Metropolis-Hastings algorithm)

- MH(Metropolis-Hastings) is the basic algorithm of MCMC
- MH algorithm
 - MH란?
 - Target distribution인 $P(Z)$ 에 비례하는 임의의 함수 $f(Z)$ 를 계산할 수 있을 때 $P(Z)$ 를 MCMC 샘플링 할 수 있는 알고리즘
 - 현재 z^t 라고 assignment 되어있는 것을 다음 transient를 통해 어떠한 assignment로 바뀔지 candidate하는 것. 기존의 정보를 활용(z^t)에서 제안하는 것이 MCMC의 근간에서 따온 것
→ 이 것을 **Proposal distribution**이라 함
 - $f(z)$ 만으로는 $p(z)$ 샘플링 불가
→ $q(z^t|z)$ 라는 쉽게 샘플링이 가능한 조건부 확률 분포 proposal distribution이 필요
이전 상태 z 로 부터 다음 상태 z^t 예측
 - α (acceptance probability)에 따라 coin toss를 해서 accept가 일어나면 $z^*(\text{candidate})$ 를 받아들이고 reject되면 기존의 z^t 를 사용

M-H algorithm (Metropolis-Hastings algorithm)

▪ *step1*

- $p(z)$: target density
- $q(z)$: proposal density
 - $z^* \sim q(z^* | z^t)$: 새로 뽑는 샘플이 이전 샘플에 종속

▪ *Step2*

- Calculate the ratio, $r(z^* | z^t) = \frac{q(z^t | z^*)p(z^*)}{q(z^* | z^t)p(z^t)}$: q를 가우시안 분포로 사용

▪ *step3*

- $u \sim U(0,1)$
- $\alpha(z^* | z^t) = \min(1, r(z^* | z^t))$: 알파가 1보다 작거나 같은 값이 추출됨, 1이 뽑히면 r이 1보다 크므로 무조건 accept, 그렇지 않으면 패자 부활전
- $$\begin{cases} u < \alpha(z^* | z^t) & z^{t+1} = z^* \text{ (Accept)} \\ \text{else} & z^{t+1} = z^t \text{ (Reject)} \end{cases}$$


▪ M-H algorithm을 통해 Markov chain 생성

▪ Monte Carlo 방법 적용해서 샘플링



Metropolis 예시 $f(x) = 0.3e^{-0.2x^2} + 0.7e^{-0.2(x-10)^2}$

<https://angeloyeo.github.io/2020/09/17/MCMC.html>

1. Random initialization



2. Next recommendation by proposed distribution



3. Accept or reject? ($r = \frac{p(x_1)}{p(x_0)} > 1$?)

4. In the case $r < 1$,

- Give a chance to be sampled with the probability of r

$$\frac{p(x_1)}{p(x_0)} > u ?$$

Exploration


- Accept 의 과정: Exploitation
 - 해당 봉우리만 계속 탐색
 - 제안 분포를 넓게 만들면?
- 패자부활전: Exploration
 - 다른 봉우리를 탐색할 수 있도록 유도
 - 제안 분포를 충분히 넓게 만들 수 없으므로

Gibbs Sampling

- $q(z^*|z^t) = P(Z_k^*, z_{-k}^* | z_{-k}^t) = P(Z_k^* | z_{-k}^t)$ 으로 놓으면
- $p(z^t)q(z^*|z^t) = q(z^t|z^*)p(z^*)$ 가 항상 성립
 - acceptance probability가 필요 없어짐($\alpha(z^*|z^t) = 1$)
 - 항상 reversible
 - 항상 detailed balance equation이 자동으로 만족
- $$\begin{aligned} p(z^t)q(z^*|z^t) &= p(z_k^t, z_{-k}^t)p(z_k^*|z_{-k}^t) \\ &= p(z_k^t, z_{-k}^t)p(z_{-k}^t)p(z_k^*|z_{-k}^t) \\ &= p(z_k^t|z_{-k}^t)p(z_k^*, z_{-k}^t) \\ &= q(z^t|z^*)p(z^*) \end{aligned}$$

Gibbs Sampling

- A special case of M-H algorithm
- 목표분포가 다변량분포일 때 주로 이용
- 모든 단변량 조건부 밀도함수가 완전히 알려진 형태
- q 라는 것을 새롭게 만들지 말고 기존에 p 를 이용하는 것
- Latent variable z_k^* 에 대해서만 Update
- Example
 - $p(z_1, z_2, z_3)$
 - $z_1 \sim p(z_1 | z_2^t, z_3^t) \rightarrow z_1^{t+1}$
 - $z_2 \sim p(z_2 | z_1^{t+1}, z_3^t) \rightarrow z_2^{t+1}$
 - $z_3 \sim p(z_3 | z_1^{t+1}, z_2^{t+1}) \rightarrow z_3^{t+1}$



Conclusion

- EM의 경우 saddle point/local optimum point가 존재하기 때문에 더 좋은 assignment가 있어도 stop될 수 있음
- But, Sampling Based Inference의 경우 local에서 탈출할 수 있어 시간이 많으면 MCMC가 더 좋은 성능을 보임
- 짧은 시간 안에 해야 한다면 MCMC...or VI(variational inference)사용